ResumaCAD

持续人机 CAD 编辑中的几何证据维护与可靠续作

Version-Aware Geometric Evidence for Reliable Continuation in Human-AI CAD Editing

选题报告与预实验计划 | 2026-10-25 | v1.0

> 核心问题：一个共享 CAD 项目已经被人或其他 agent 修改，AI 先前获得的哪些几何证据还能用于当前行动？能否只补充必要的新观测，就正确、低成本地继续设计？

ResumaCAD 取意于 resume，突出人机交替编辑后的可靠续作。本报告记录今天形成的研究决定，为后续协议设计、基线复现和方法实验提供共同起点。研究依托现有 DBCAD 几何与版本底座，计划形成两项相互独立、可检验的贡献：持续编辑评测体系与版本感知的几何证据维护方法。

决策摘要

- 研究对象：经历需求更新、外部编辑、暂停/恢复和实体引用变化的共享三维 CAD 项目。先从零件与小装配、有限查询和操作范围开始。
- 研究动机：历史观测可能失效；全部重读又会增加观测、上下文和验证开销。需要同时考察可靠性与成本。
- 拟定路线：先构建中立协议和小型诊断，运行强基线，再决定方法；优先固定现有 VLM，不以训练新基础模型为起点。
- 当前状态：原生底座、AI 编辑入口与既有单轮 harness 对照已经完成；新的持续编辑 benchmark、证据维护机制与其效果尚未实现或验证。
- 立项边界：已有多轮 CAD、长时程 CAD、约束保持和 agent 记忆研究。本课题不以“首次长期 CAD”或“首次图记忆”为主张。

阅读路线

第 1-2 节说明问题和相关工作的边界；第 3 节说明现有基础；第 4-7 节定义目标、benchmark 和候选方法；第 8-9 节规定实验、指标和否证条件；第 10 节给出启动路径和预期成果；最后附参考文献与术语。

证据口径：文献结论来自论文或官方代码/规范的定向核对；本地结果来自既有实验报告和本轮代码/几何诊断；带“计划、候选、拟定”的内容均为待验证研究设计。定向检索不等于全领域系统综述，也不能证明未公开工作不存在。

1. 问题界定：设计变化后，旧判断何时还能用？

1.1 区分三种状态

几何状态是当前模型本身，包括实体、拓扑、尺寸和装配位置；要求状态是当前仍有效的设计要求，包括新要求取代旧要求的关系；认知状态是 AI 保留的观测、判断、目标绑定和未提交计划。研究关注三者在版本演化中的一致性。

几何内核能执行精确运算和检查部分几何合法性，但合法 B-Rep 不自动代表孔径正确、装配间隙合格或设计意图满足。历史测量曾经正确，也不自动代表它现在能作为行动依据。反过来，用户将孔径从 6 改为 8 是合法的新要求，应取代旧要求，不能被系统错误阻止。

1.2 一个贯穿报告的任务情境

下表是拟定的说明性场景，不是已完成的长期实验。单位、保护项与新要求应在真实任务中显式给出。

阶段	项目事件	AI 需要处理的状态
v1	AI 检查带孔底板和安装空间，记录当前孔径及无干涉结论	将观测绑定到该版本、实例、参考系和查询范围
v2	人修改远处的线缆支架	判断是否真正影响现有证据，避免无谓全量重测
v3	新要求扩大目标孔，取代原孔径要求	撤销旧尺寸事实的当前用途，并更新要求状态
v4	人将另一零件移入原插入区域；AI 没有执行该操作	即使孔未变化，也重新检查区域无障碍判断
v5	AI 恢复工作，要求继续安装并保护现有支架	基于当前证据续作；必要时重新定位、测量或澄清冲突

1.3 五个必须分开的实验维度

维度	含义及控制方式
修订历史长度	项目经历多少次语义修改；增加无关版本时保持当前任务难度不变
需求与引用跨度	当前任务依赖多久以前的角色、决定或历史状态；不等于工具调用次数
外部变化	由人或其他 agent 产生的变化；所有方法获得相同通知与查询权限
几何规模与变更范围	组件/面数、关系耦合、局部与全局编辑；与历史长度分别变化
模型上下文长度	实际发送的历史/图像/token；允许系统检索、摘要和读取最新快照

初期范围：尺寸、距离阈值和指定区域干涉等可执行查询，以及原生工具能够稳定执行的编辑。大装配、自由曲面、通用自动合并和多人实时并发不是第一阶段同时承诺的目标。

2. 相关工作与启发：哪些部分已经被研究？

2.1 CAD 修改、长时程操作与约束保持

相关工作	已有覆盖、对我们的启发与区别
mrCAD [1]	2D CAD 多轮人类交流与修改，含 6,082 个游戏、15,163 个指令-执行轮次。启发是保留真实上下文引用与人类修订表达；它排除了“首次多轮 CAD”的主张。
neuralCAD-Edit [2]	专家提出 192 个多模态编辑请求并提供 384 个编辑。启发是编辑已有模型、使用真实请求而非仅从零生成；其请求级评价不能直接替代持续共享项目评价。
AgenticCADedit [3]	有状态工具调用、检查、渲染、撤销形成编辑闭环。可作为续作方法的宿主；已有状态性不代表已解决跨会话外部变化后的证据有效性。
IterCAD [4]	代码-执行-视觉反馈迭代，包含 200 个局部编辑测试任务。启发是几何反馈和逐步修正；一个目标内的修复轮次不等于多条独立需求的项目生命周期。
CADWorld [5]	200 个 FreeCAD 任务、11 类工程工作流；报告实验最大 100 GUI 步/任务，终态检查工程文件。启发是工程产物验收；“长时程 CAD benchmark”已经存在。
HistCAD [6]	显式建模约束，并在局部尺寸编辑后区分有效状态可达性与其他约束的保持。启发是目标项和保留项独立评价；建模 history 不自动等于人机交替提交的版本链。

这些工作说明，前沿已经覆盖生成、修改、修复、交互、工程工作流和约束。不能将研究背景写为“大家仍然只做自然语言生成”。更准确的定位是：在已具备这些能力的系统上，进一步研究变化后的证据如何支持持续行动。

2.2 从建模过程图与持续状态获得什么路线？

TraceCAD [7] 将需求、建模步骤、错误证据和结果保存为恢复状态，并进行依赖域内修复和技能复用。它提示我们将计划与依据关联，也意味着持久状态、局部修复和经验记忆不是独立新意。

CADIR [8] 记录操作、参数、约束与拓扑选择的 construction graph，支持图/子图检索和几何签名匹配。它提示使用结构化依赖；但 DBCAD 的几何快照图不能冒充建模过程图，实体匹配也不能凭空假设已解决。

MUSE [9] 在 3D 场景创作中维护场景记忆和保护集，并评测 50 条三阶段链，即一次构建加两次连续编辑。它提示跨轮状态与每轮重建可分离；连续编辑链本身也已经有近邻研究。

2. 相关工作与启发（续）：记忆的一致性不是新概念

2.3 通用 agent 与经典算法的直接近邻

工作	已有机制	对 ResumaCAD 的约束与启发
Concord [10]	关联工具观测与可变来源，根据版本/范围检测失效，并刷新或抑制上下文	是最直接的通用近邻。必须比较合理的 CAD adapter；仅增加 CAD 接口不够。
TRACE [11]	agent 返回变化后的共享状态时，处理显式/隐式失效并准入所需记忆	返回与记忆准入问题已经被定义；CAD 增量应体现在几何依据及实际收益。
MemTX [12]	带来源与有效性的记忆、事务暂存与提交、动作门控及级联修复	事务、依赖传播和行动前校验须作为已有思想，不应重新命名为原创。
经典几何/协作研究 [13][14]	增量距离计算利用几何连续性；多用户 CAD 区分语法与语义冲突	空间索引、距离界和语义冲突都有基础。应比较这些简单而强的机制。

2.4 工程实现已经做到哪一步？

ARK [15] 已有项目隔离、跨会话本地记忆、语义检索和操作收据；其文档明确区分记忆修订与当前 CAD 几何权威。lambdacad [16] 会记录人的手工增删改，并在报告时重验标签实体是否存活；存活仍不等于旧尺寸或间隙成立。AgentCAD [17] 的官方规范包含 JSON 记忆、决策、预算上下文与受控写入。规范覆盖不等于已完成长期效果验证。

因此，“JSON + 图数据库 + 向量检索 + 版本号”不足以支撑本课题。图数据库是可替换的承载层，不应成为评分偏好或论文结论的前提。

2.5 本课题当前可以主张什么？

候选测量缺口：在所核对的 CAD 协议中，尚未看到专门统一评测“共享项目外部变化、历史几何证据有效性、要求更新与暂停后续作”的直接证据。应通过新协议分离这些因素，而非只延长现有动作链。

候选方法增量：从 CAD 查询与编辑中构造几何依赖和保守有效条件，覆盖实例/参考系、拓扑不确定性及区域否定查询中的潜在新对象，并连接到续作和重新规划。

待确认的关键点：合理的空间失效策略或 Concord CAD adapter 是否已经足够？如果答案是肯定的，应承认该结果，调整或停止复杂方法。文献未见直接评测，不自动证明问题在实践中频繁，也不证明候选方法有效。

3. 已有基础与证据：我们从哪里开始？

3.1 DBCAD 能提供的实验底座

当前系统以 C++ ACIS worker 执行几何命令；FastAPI 管理命令与版本；内容寻址资产库保存 SAT/GLB/graph；Neo4j 管理版本清单与实体投影。SAT + 版本清单是权威状态，JSON 图是派生查询索引。BFS 遍历和关系提取使拓扑可查询，但不自动恢复设计意图。

已有版本、不可变组件、实体内容键、候选血缘与隔离 AI 预览，使我们可以定位证据来源、追踪变化并重放诊断。当前 AI 应用严格核对 base_version；工具覆盖图元、变换、删除与布尔，尚不覆盖全部局部特征操作。

仍需补齐的能力包括类型化几何查询、实例/参考系绑定、来源与覆盖收据、保守失效、上下文重建和持续事件评测。当前实体键不包含完整关系邻域，后备血缘匹配按类型和出现顺序贪心配对，不能直接充当稳定语义身份保证。

3.2 既有三 harness 实验的真实含义

已有报告 [L1] 完成 neuralCAD-Edit 分层子集上的 24 请求 × 3 方法，共 72 次正式运行，统一使用 Qwen3.6-27B，并限制为六次模型调用。以下仅为可用实体统计。

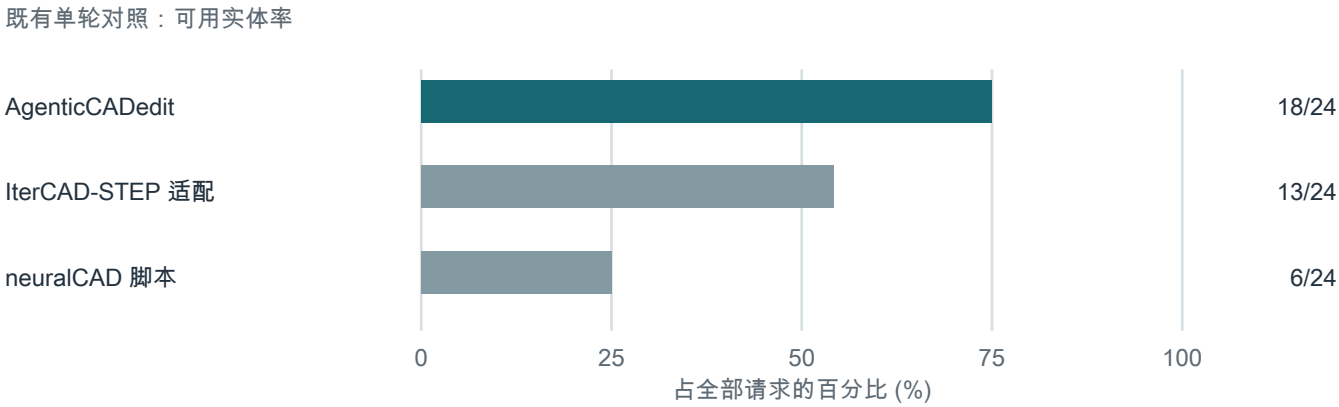


图 1. 既有单轮实验的可用实体率。横轴为占全部 24 个请求的百分比，标签给出分子/分母；不是语义编辑成功率，也不是论文原始系统的完整复现成绩。

AgenticCADedit 为 18/24，IterCAD-STEP 适配版为 13/24，脚本基线为 6/24。IterCAD 未使用作者训练权重；STEP 输入有适配。三个 VLM 代理通过样例中，后验审计发现至少两个有明显非目标变化，所以原代理分数不能可靠裁定语义胜者。该实验提供流程、工具和评分经验，尚未测长期续作。

3.3 已跑通的离线反例，不是方法性能

- 关系失效：孔半径 6 mm 的底板不变，障碍物移入半径 5 mm 的规定插入区域，内核相交体积由 0 变为约 64 mm³。目标未变不代表区域无障碍判断仍成立。
- 命题与数值不同：两个方块距离从 5 变为 5.5 mm。旧数值过期，但在已证明扰动不超过 0.5 mm 时，4.5 mm 下界仍可支持“距离至少 3 mm”。
- 对应不确定：调用当前实体匹配函数，在两张平面重新编号并交换枚举顺序的合成输入上出现左右错配。它说明后备策略无身份保证，不是实际模型失配率。

4. 研究目标、问题与贡献边界

4.1 总体目标

构建一个可复现的持续 CAD 编辑研究环境，识别版本演化中证据失效导致的错误；提出可核验、可回退的证据维护机制，在保持任务可靠性的同时减少不必要的重新观测和上下文开销。第一阶段不训练新基础模型，也不将 ACIS 替换或图数据库性能优化当作主要创新。

研究问题	可检验的假设	可能否定该假设的结果
RQ1：问题有多普遍？	外部变化、引用变化和要求取代会增加旧证据误用，并影响续作	合理的最新状态基线已稳定解决，历史条件没有额外影响
RQ2：几何机制是否必要？	查询级依赖及保守有效条件比粗粒度失效更好兼顾保留与防错	AABB/组件失效或 Concord adapter 已解释全部收益
RQ3：能否改善端到端表现？	维护收益超过构图、检索、重验和重新规划开销	仅少量内核查询变少，总费用/延迟和成功率无实质改善
RQ4：能否迁移？	同一证据协议在不同 harness、模型及几何后端上仍有用	只在单一模板、单模型或刚体位移任务上有效

4.2 两项候选贡献，分别验收

贡献 A：评测协议与数据。 提供有版本事件和要求生命周期的项目任务、两种评测轨道、独立验收器、统一观测权限、可审计轨迹与强基线。评测应揭示已有任务分数无法区分的失效机制，并在未见项目上保持有效。

贡献 B：几何证据维护方法。 实现从查询与编辑到依赖/有效条件的机制，处理保留、撤销、重验和未知状态，并将结果接到持续编辑的上下文与行动检查。方法不能只在为自己设计的评分器上占优。

两者可以在同一篇论文中联合呈现，但不能互相充当真实性证明：benchmark 需要独立的任务与真值依据；方法需要胜过强对照并通过消融。新增 benchmark 并不自动保证新增方法具有足够贡献。

4.3 初期可控范围与后续扩展

初期支持三类命题：解析孔/局部尺寸、对象最小距离阈值、指定区域无干涉。对不支持的几何、歧义对应或不可证明的编辑影响返回未知并重验。尺寸识别、角色绑定和变更覆盖均要计入系统成本及失败率。

后续扩展包括更长历史、更大装配、复杂局部操作与人机交替修改的安全续作。通用分支合并、实时多写者、完整物理/制造可行性和大型模型训练，均需在核心假设成立后另行立项。

5. Benchmark 设计：评价持续项目，而非堆叠调用

5.1 一个项目任务包应包含什么？

对象	内容与可见性
初始状态 G0	可读取的 STEP/原生模型、单位、坐标系、初始版本和组件作用域
请求序列 U	按阶段开放的新编辑目标、保护项和合理的历史引用；不提前展示未来请求
事件序列 E	人工/其他 agent 的编辑、作者、版本、通知与暂停恢复时机
要求状态 R	要求的生效、取代、撤销和关联对象；系统可见信息与隐藏验收标注明确分离
预算与接口 B	所有方法同等的查询、版本访问、通知、操作和费用约束
独立评价器 J	检查当前目标、仍有效保护项及冲突处置；不读取方法内部证书来决定对错

5.2 两条互补轨道

轨道 A：固定检查点的证据诊断。 从统一历史状态出发，让系统先获得一组观测，再注入受控变化，检查旧命题的准入、重验和保留。所有方法面对相同几何事实，便于因果定位；该轨道不代表完整长期编辑成功率。

轨道 B：闭环持续编辑。 下一阶段继承各方法实际产生的模型和历史，评估其完成任务、保护设计、发现失效和恢复的能力。外部变化由可应用的语义操作定义；不能在每阶段载入标准快照，覆盖被测系统之前的修改。

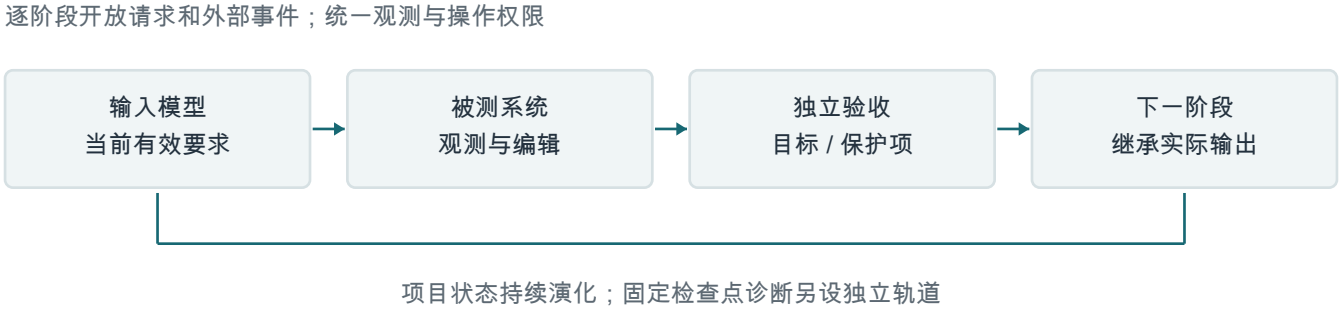


图 2. 闭环评测：请求与外部事件驱动同一被测项目演化；独立验收逐阶段记录目标、保护项、错误和成本。所有未来答案与标准修复过程对 agent 隐藏。

5.3 保证任务可执行与比较公平

外部操作需要明确附着条件、实体定位方式和失败策略。若被测模型已偏离到无法执行事件，应记录任务诱发失败或环境失败的类别，按预注册规则处理，不能为某方法临时重置或跳过。合法的要求更新不能被旧保护项阻止；确实不可同时满足的请求应允许澄清，同时统计过度拒绝。

所有方法可以读取当前模型、收到相同版本更新并调用相同查询。不能要求系统猜测不可观测的人工编辑，也不能只向候选方法提供标准实体绑定。长上下文策略、检索策略和每次重新测量策略都应有公平发挥空间。

6. 数据、场景与规模：从可诊断走向可信

6.1 第一批受控诊断

拟定从 20 个参数化场景构造六类变化，共 120 个变化后检查点。它用于验证评价器和失效机制，不是 120 条已完成的长期项目链，也不是论文级自然场景频率估计。数量可随先导结果调整。

变化类别	主要检验点	拟定检查点
不相干区域修改	有效证据应保留，整项目失效是否过度重测	20
局部尺寸/几何修改	旧尺寸和相关推论不应继续使用	20
新增或移入障碍物	否定查询必须考虑原结果集外的潜在对象	20
局部/整体刚体变换	局部不变量和世界坐标关系要区分	20
重编号、分裂与合并	不确定对应不能静默继承旧判断	20
撤销/恢复、参考系或单位变化	正确版本绑定、换算与证据恢复	20

6.2 闭环项目链与难度控制

先做少量 5 阶段小装配，跑通继承、变更和验收；之后拟扩展到 20/50 阶段，并独立改变引用跨度、外部变动率、组件数和几何复杂度。全局编辑可能使大部分记忆失效，必须纳入压力测试，不能只选局部变化让复用天然占优。

场景至少包含安装孔与邻件间隙、安装区域被新增零件占据、阵列/支架位置调整和合法要求取代。自然语言既包含明确数值，也包含“上一版那个孔”等历史引用。对歧义和无解请求设置明确的评价规则。

6.3 数据来源、切分与真实性

先用具有解析真值的参数化几何校准评价器，再加入许可允许的外部 STEP 和人工设计的编辑序列；邀请熟悉 CAD 的人员检查任务合理性。脚本模拟的人类事件须标为模拟，不能称为真实协作用户实验。

训练/开发/测试按零件或装配家族切分，不让同模板不同尺寸随机落入两侧。保留未见形状和未见变化组合；开发集用于选规则，冻结测试集后不按候选方法失败案例反复修改评分标准。

公开包计划提供 STEP、事件描述、标注规范、开放查询与验收接口、数据来源和许可记录。OCP 参考后端用于低门槛复现，ACIS/DBCAD 用于另一后端验证；两者不能在主方法比较中随意混用而引入内核差异。

7. 候选方法：版本感知的几何证据维护

7.1 存储单位从“模型文本”变为“可检验命题”

几何快照、原始观测、当前有效命题和设计要求分别存储。JSON/图数据库负责索引与溯源，几何内核负责受支持查询的求值。原始观测保留为历史，不因上下文更新被改写成“当时测到新数值”。

证据字段	作用
query / predicate	类型化的可执行查询及比较条件，例如距离是否至少 3 mm
source / version	项目、来源版本、组件/资产及查询提供者标识
occurrence / binding	实体实例、目标角色和对应依据；不能只依赖共享内容键
frame / unit / tolerance	局部或世界参考系、单位与内核公差
result / witness	原始数值或命题结果及见证；精确值与推得下界分开
dependencies / domain	实体、关系、空间查询域与潜在对象集合的依赖
guard / coverage	允许复用的保守条件，以及序列化/编辑影响覆盖是否完整
status / provenance	当前有效、失效、未知或仅历史记录，并说明原因与验证版本

7.2 从变化到行动的闭环

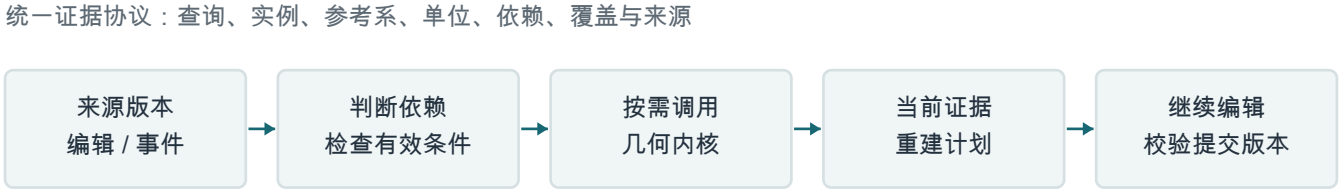


图 3. 候选证据维护层。来源变化先进入有效性判断，必要时调用内核；只有当前任务所需的有效证据进入后续行动。最终提交仍校验版本。

1. 记录观测：在一致版本上绑定实例、参考系、用途和依赖，不认证 LLM 自述。
2. 消费变化：读取受控编辑收据和场景变化，校验新增、删除、改形、变换及回退的覆盖。
3. 判断有效性：有保守依据才复用命题；需要精确值或覆盖不明时重验/返回未知。
4. 重建上下文：提供当前有效证据和变化摘要，撤销失效依据对应的未提交计划。
5. 提交检查：校验 head；需前移时在当前状态重放并重验，不能覆盖旧全量清单。

普通的来源关联、级联更新和提交检查并非原创。待研究的核心是 CAD 查询依赖与保守有效条件的构造，以及其相对通用 adapter 的增量价值。

7. 候选方法（续）：三类关键几何情形

7.3 命题可以有效，旧精确数值不能冒充当前值

设两个几何集合原最小距离为 d0；若已证明它们各自的 Hausdorff 变化界不超过 a、b，则可使用保守下界 d_new ≥ d0 - a - b。判断阈值为 tau 时，只有下界连同公差仍不小于 tau，才可维持相应安全命题。这个基本距离稳定性不是新定理。

例如 d0=5 mm，一方已知平移界为 0.5 mm，另一方不变，则 4.5 mm 下界足以支持“至少 3 mm”。系统只能呈现这一命题或下界，不能继续把 5 mm 标为当前测量。未知布尔编辑、无变化界或新增对象不能擅自套用刚体界。

7.4 否定空间查询要覆盖“原先没有的对象”

“区域 Q 内不存在障碍”依赖的是对候选对象的完整覆盖。只跟踪已经命中的对象会遗漏新增零件。拟用空间候选更新和保守包围域识别新进入者；只要覆盖或界无法确认，就重新执行精确查询。AABB 等简单空间机制必须作为强基线。

7.5 身份、参考系与要求生命周期

刚体移动通常不改变局部孔半径，却会改变世界位置或与其他零件的关系。相同几何属性不代表相同实例；split/merge 后的实体不能仅凭枚举号续接记忆。第一阶段优先使用明确操作来源和可验证绑定，遇到歧义就重定位/失效，不同时承担新的通用拓扑命名算法。

要求可以被新要求取代，证据也可以保持历史正确却失去当前用途。需要显式记录这两类生命周期，避免把旧要求当成“记忆必须保持”的永久约束。对受污染的推理后缀，优先从准入后的状态重建计划，不要求 LLM 自己猜哪些旧推理应作废。

7.6 技术落地顺序

步骤	实现位置与产出
先跑通开放原型	在现有 CadQuery/OCP 研究环境实现统一查询、事件和独立评价，先固定一个 harness
定义中立证据协议	查询/版本/实例/单位/覆盖/有效性字段；依赖图存储与算法接口分离
接入 DBCAD	通过原生 worker 增补测量；Python 网关只处理中立值，ACIS 仍只存在于 worker
建立保守回退	投影不完整、实体对应未知或编辑不支持时重新查询；记录覆盖与重验成本
迁移与优化	核心假设成立后再增加第二模型/harness 和后端；最后才考虑学习式调度或策略训练

现有 /diff 的实体键集合与候选 DERIVED_FROM 只可提供线索，不足以直接认证全部几何影响。数据库去重和实体匹配修复属于必要工程，不自动构成新研究贡献。

8. 对比实验：证明收益来自哪里

8.1 主对照与上界

对照	目的及公平要求
B0：最新模型 + 有效要求 + 按需新鲜查询	最重要的简单基线。允许充分读取当前状态，检验是否真的需要历史证据维护
B1：追加历史、固定窗口或普通摘要/检索	比较上下文组织；给相同工具能力，并记录实际 token 与维护成本
B2：组件哈希/实体内容键失效	测粗粒度与内容级复用；不将内容共享当实体身份真值
B3：保守空间域与 AABB 依赖	强几何基线，必须监听新增/移入对象，不能故意限制为已知目标
B4：Concord 的合理 CAD adapter	对比通用来源失效框架。若放入相同 guard 后机制等价，应承认等价
B5：TRACE 准入或 MUSE 式每轮重建适配	在核心诊断后按资源选择，明确适配细节，不冒称逐字复现原系统
Oracle：正确有效性/目标绑定	只作可达上界和瓶颈诊断，不计作自动方法成绩

首轮拟沿用 AgenticCADedit 式工具闭环 + Qwen3.6-27B + OCP 查询原型，以复用已有环境；同一模型、编辑器和后端上只比较证据机制。新协议结果独立计分，不沿用旧单轮成绩。它是可用起点，不代表最强模型；API 别名也不证明与论文权重一致。离线通过后，再在第二 harness、第二模型、不同预算和 ACIS 适配上检查迁移；适配版须明确命名，付费执行另行核对预算。

8.2 必要消融

- 去掉空间否定依赖：是否在新增障碍时误用旧结论？
- 去掉保守几何界：是否退化为更多精确重验，影响总体代价？
- 去掉实例/参考系信息：是否出现错误绑定或错误不变量传播？
- 整组件依赖与查询级依赖：收益是否只来自更细的普通缓存？
- 同等上下文预算的普通压缩：是否只因文字少、图像少而获益？
- 去掉失效后的计划重建：仅更新观测能否阻止旧计划继续执行？

8.3 公平性与失效归因

固定请求、外部变化、可见信息、工具接口与验收；比较时记录模型实际版本、输出上限和采样参数。统一操作数上限不等于同样推理预算，要同时报告模型、图像、查询、维护和时间成本。缓存命中字段缺失应标为未知。

加入无外部变化、无关变化和要求合法取代等负控制，避免通过“始终重验/拒绝”刷低危险率。内核/环境错误、查询绑定错误、证据失效漏判、要求误读与普通建模失败分别归因；不得把所有失败都归咎于记忆。

9. 指标、统计与推进门槛

9.1 不用单一相似度代替工程验收

指标	定义及解释
阶段成功率	当前目标和仍有效保护项同时满足的阶段数 / 全部预定阶段数；合理冲突处置单列
整链成功率	全部要求阶段均通过的项目链比例；与阶段分数同时报告
首个严重错误位置	每条链首次发生保护项损伤、危险旧判断使用或错误提交的阶段；未发生者作截尾记录
旧证据误用率	真正失效却作为当前行动依据的旧命题 / 被用于行动的可核验旧命题；分母为零单列
有效证据保留率	当前任务需要且仍成立的历史命题中，被正确保留并可用的比例
重验/未知/覆盖	分别统计精确重验量、未知比例和支持范围，避免全部遗忘被误判成优秀记忆
恢复与总体代价	错误后恢复步数、重复操作、模型输入/输出与图像费用、内核/维护时间、端到端延迟

真值以独立查询/验收为准，不能直接采用候选方法自己的证书或 LLM 自评分。正确冲突提示、过度拒绝、目标未完成和不受支持类型要分别统计。通孔/间隙等要求优先用几何量验证；主观意图仍需要盲评或人工核验。

9.2 统计与因果解释

按同一项目/事件序列做成对比较，统计不确定性以项目为单位聚类或 bootstrap；同一项目中的多个阶段不是独立样本。预注册主指标、预算、缺失处理和停止规则，探索性分析另列。开发集选择规则后，在冻结测试集上一次性核验。

链越长，全链成功率会自然下降。例如每阶段成功概率固定为 0.95 且独立，50 阶段全成功概率也只有约 7.7%。这是数学说明，不是模型实验结果；不能仅凭长链退化证明记忆失效。必须结合成对控制和具体错误轨迹。

9.3 拟定的推进与停止条件

预实验要求受控支持范围内未发现错误准入，同时保留足够有效证据；争取相对最强几何基线减少至少 30% 精确查询，再检查端到端质量-费用/延迟是否仍有实质改善。30% 是事先讨论的工程决策阈值，不是已测结果或论文承诺。 有限集零错误也不是普遍安全证明。

若最新状态或空间依赖基线已经足够、真实续作中问题罕见、保守规则导致几乎全重验、维护成本吞掉节省，或换项目/模型后收益消失，应停止复杂机制。仅有内核毫秒级收益而不改善可靠性或总体代价，不足以支撑宽泛的 AI-CAD 方法结论。

10. 如何开始、阶段交付与预期结果

10.1 建议的六阶段节奏

下表是按约六周组织的研究顺序，不是交付日期承诺。每阶段以证据决定是否进入下一阶段，必要时收缩范围或回退。

阶段	主要工作	完成标志
第 1 阶段：协议与真值	冻结任务定义、可见权限、事件/要求生命周期和错误分类；选小装配场景	有可运行最小任务包、解析校准和独立验收说明
第 2 阶段：问题诊断	构建拟定的 120 检查点；运行最新状态、粗粒度和空间强基线	能定位失效模式及不确定性，确认值得研究的差距
第 3 阶段：最小机制	实现三类查询证据、保守依赖/guard、未知回退和上下文重建	离线与新鲜内核结果一致；比较维护开销而非只看命中率
第 4 阶段：闭环续作	接一个 harness，运行短项目链，再按结果扩展长度	无标准快照覆盖，逐阶段目标/保护项与费用可追溯
第 5 阶段：验证与消融	冻结测试、第二模型/harness、必要 ACIS 迁移与压力条件	主指标、消融和强基线对照一致，失败案例完整保留
第 6 阶段：论文与发布	整理数据卡、复现脚本、图表、相关工作和局限	形成可审阅论文初稿与可复现研究包；不保证录用

10.2 第一个工作周期的具体动作

1. 写出三种示例任务包与当前要求清单，定义一个合法要求取代和一个新增障碍事件。
2. 确立统一查询返回：版本、单位、参考系、对象绑定和失败/未知原因；先不加入学习策略。
3. 对解析尺寸、最小距离和区域干涉校准独立评价器；制造已知错误，确认它确实会拒绝。
4. 先跑最新状态全重验和空间依赖基线，保存成对轨迹；确认差距后再设计复杂机制。
5. 确定测试划分、指标与新增模型预算。现有 M5/24 GB 环境用于内核与诊断，付费 API 另行核对预算；本报告没有新增模型调用。

10.3 期望产出与主要风险

期望形成三类成果：可复现的持续编辑协议与数据；有明确适用范围、可回退的证据维护方法；解释何种变化使现有系统失效、何种情况下简单基线已经足够的实证分析。论文叙事应由问题、证据和机制连接起来，而非仅展示新架构图。

主要风险是近邻机制已足够、任务过度合成、绑定/评价器错误、内核差异和维护成本。对应措施是先跑强基线、引入独立场景与人工合理性审核、交叉核验、固定主后端并另做迁移实验、完整计费。不要因沉没成本持续包装没有额外收益的机制。

今天的结束点：题目与研究边界已确定，工程准备可用；明天应从协议和强基线诊断开始。benchmark、方法效果和发表新颖性仍是研究要检验的结果，不是本报告已证明的结论。

参考文献与核对入口（一）

以下为正文使用的原始论文或官方来源。核对日期为 2026-10-25；论文方法、官方工程文档与本地实测在正文中分别表述。除已复现项目外，引用不代表本机重新复现其结果。

[1] mrCAD: Multimodal Communication to Refine Computer-aided Designs

EMNLP Findings, 2025。核对多轮 2D CAD 的 Designer/Maker 任务及数据规模。ACL Anthology；官方环境与代码。

[2] neuralCAD-Edit: An Expert Benchmark for Multimodal-Instructed 3D CAD Model Editing

2026。核对专家请求、输入模型、编辑流程与评价范围。arXiv:2604.16170。

[3] AgenticCADedit: A Stateful, Tool-Mediated Agentic Approach to Multimodal 3D CAD Editing

2026。核对状态环境、MCP 工具与编辑循环。arXiv:2609.29621。

[4] IterCAD: An Iterative Multimodal Agent for Visually-Grounded CAD Generation and Editing

2026，v3。核对交互协议、局部修改任务与迭代反馈。arXiv:2606.13368。

[5] CADWorld: Computer-Use Benchmark for Long-Horizon Computer-Aided Design

2026。核对任务单位、FreeCAD GUI 协议、100 步实验上限与产物验收，重点为 §3 与附录 B/D。arXiv:2609.16251v1。

[6] HistCAD: A Constraint-Aware Parametric History-Based CAD Representation, Dataset, and Benchmark with Industrial Complexity

2026，v3。核对 §4 的尺寸编辑、目标约束、保留集合以及 ER/cPCSR/OES 指标。arXiv:2602.19171v3。

[7] TraceCAD: Trace-Guided Repair for Agentic CAD Generation

2026。核对持续恢复状态、依赖域内修复与技能记忆。arXiv:2608.03062。与参考文献 [11] 的 TRACE 不同。

[8] CADIR: A Cross-Backend Editable Intermediate Representation for Agentic CAD Generation

2026。核对 construction graph、子图检索与几何签名匹配。arXiv:2608.00891。

[9] MUSE: Agentic 3D Scene Authoring via Memory-Grounded Incremental Requirement Satisfaction

2026。核对跨轮记忆规则 A.3-A.5，以及 C.2 的 50 条三阶段连续编辑链。arXiv:2606.14168。

参考文献与核对入口（二）

[10] When Agent Context Goes Stale: Incoherence in Volatile Agent Context

2026，Concord。核对 §3-4 的来源绑定、范围失效、上下文修复和 adapter 接口。arXiv:2610.05281。

[11] TRACE: Governing Memory Validity in Evolving Multi-Agent Systems

2026。核对返回检查点、显式/隐式失效与预算内记忆准入。arXiv:2609.33517。

[12] MemTX: Transactional Belief Commit for Stateful Agent Memory

2026。核对事务、有效性、动作门控与级联修复的协议范围。arXiv:2607.23929。

[13] Planning Algorithms, §5.3.3 Incremental Methods

Steven M. LaValle。作者教材网页说明利用几何连续性的增量距离计算，作为经典算法基础。原始章节。

[14] Automated Conflict Avoidance in Multi-user CAD

Computer-Aided Design & Applications, 11(2), 141-152。核对语法/语义冲突分类与特征预留。期刊原文。

[15] ARK: Persistent Memory for ARK Agents

官方工程文档，非论文性能结论。核对持久记忆、来源声明与当前几何权威的边界。官方说明。

[16] lambdacad-mcp: memory_enable / tag_entity / world_report

官方代码，BricsCAD 场景。核对人工修改日志、handle 标签与存活重验范围。server.py。

[17] AgentCAD: MCP Interface Specification

官方规范，非本轮实测。核对项目记忆、决策、预算上下文与受控写入。官方规范。

[L1] 本地证据与可追溯位置

既有实验：三 harness 报告。代码核对入口：架构 ADR-3、实体投影与匹配、命令与版本检查、AI 预览应用。本报告不将代码审计和合成反例当作大规模性能结果。

术语：B-Rep 为边界表示；harness 为工具/观测/执行循环；VLM 为视觉语言模型，vLLM 通常指推理服务框架；predicate 为可求值几何命题；guard 为保守有效条件；episode 为一次评测过程，项目链由多个阶段组成。

复现：可编辑源稿为本文件；在具备 ReportLab 和中文 TTF 字体的 Python 环境执行 python docs/research/build_proposal.py。PDF 位于 output/pdf/resumacad-research-proposal.pdf；排版图示和既有统计均由脚本生成，不包含私有模型或第三方论文图片。